

驾驶员疲劳检测项目报告

1. 项目概述

本项目面向驾驶员疲劳状态的图像二分类任务，目标是根据驾驶员面部图像判断其是否处于疲劳/困倦状态。项目中的类别标签分为两类：`notdrowsy` 表示清醒或非疲劳状态，标签为 0；`drowsy` 表示疲劳或困倦状态，标签为 1。数据集已经被划分为训练集、验证集和测试集，目录结构为 `dataset_split/train`、`dataset_split/val` 和 `dataset_split/test`。

本项目并没有直接训练 CNN、RNN、Transformer 等端到端深度学习模型，而是采用“人脸关键点检测 + 人工特征提取 + 传统机器学习分类器”的方案。具体来说，首先使用 MediaPipe Face Mesh 对图像中的人脸进行关键点定位，然后根据眼睛、嘴部、眉眼关系、人脸几何形状和图像质量等信息构造特征向量，最后使用传统机器学习分类器完成疲劳状态预测。

仓库中包含两个版本：

- `DriverFatigueDetection-v0`：基线版本，主要使用 EAR（Eye Aspect Ratio，眼睛纵横比）和 MAR（Mouth Aspect Ratio，嘴部纵横比）等少量特征，包含规则阈值法和 SVM 分类器两种方案。
- `DriverFatigueDetection-v1`：改进版本，在 v0 的基础上扩展到 35 个手工特征，并使用 `HistGradientBoostingClassifier` 作为最终分类器。该版本在当前测试集上取得了更高的分类准确率，因此本报告主要围绕 v1 方法展开。

2. 使用的方法与模型概述

本项目最终采用的方案可以概括为以下流程：

1. **图像读取与预处理**：读取驾驶员面部图像，并计算亮度、对比度、模糊度等图像质量信息。
2. **人脸关键点检测**：使用 MediaPipe Face Mesh 检测人脸关键点。Face Mesh 可以输出较密集的人脸 landmarks，为后续计算眼睛、嘴部、眉毛、鼻尖、下巴等区域的几何关系提供基础。
3. **人工特征构造**：根据关键点坐标计算 35 维特征，包括眼睛开合、嘴部开合、人脸宽高比、头部姿态代理特征、眉眼距离和图像质量特征等。
4. **缺失值处理**：使用 `SimpleImputer(strategy="median")` 对可能出现的缺失值进行中位数填充。
5. **分类模型训练**：使用 `HistGradientBoostingClassifier` 训练二分类模型，输出 `notdrowsy` 或 `drowsy`。
6. **模型评估**：在训练集、验证集、测试集上计算准确率、平衡准确率、F1、ROC AUC、混淆矩阵和分类报告。

选择该方法的原因如下：

- **可解释性较强**：相比端到端深度学习模型，EAR、MAR、人脸宽高比、眉眼距离等特征具有比较明确的生理或几何含义。例如，疲劳时可能出现眼睛闭合程度增加、嘴部张开打哈欠、面部姿态变化等现象。
- **训练成本较低**：传统机器学习模型不需要大量 GPU 资源，训练和推理成本相对较低，适合课程实践和 baseline 对比。

- **对中小规模数据较友好**：在特征设计合理的情况下，梯度提升树模型能够较好地处理非线性关系，并且对特征缩放要求不高。
- **性能优于简单规则**：规则阈值方法只能根据固定阈值进行判断，难以适应不同驾驶员、不同拍摄角度和不同光照条件；而梯度提升树可以从数据中学习多特征组合关系，因此在测试集上明显优于 v0 规则阈值和 v0 SVM。

需要说明的是，MediaPipe 在本项目中只用于人脸关键点提取，并不是本项目训练出的分类模型。最终训练的疲劳识别模型仍然是 scikit-learn 中的传统机器学习分类器。

3. 特征设计

v1 版本使用固定的 35 维特征，特征 schema 版本为 v1_feature_schema_001。这些特征大致可以分为以下几类。

3.1 眼睛开合特征

眼睛状态是疲劳检测中最常见、最重要的信息之一。项目计算了左右眼 EAR、平均 EAR、最小 EAR、最大 EAR、左右眼差异和左右眼比例等特征。通常情况下，疲劳或困倦状态可能伴随眼睛开合程度降低、闭眼时间增加或双眼状态不对称等现象。

相关特征包括：

- ear_left
- ear_right
- ear_mean
- ear_min
- ear_max
- ear_diff_abs
- ear_ratio_left_right
- left_eye_width_norm
- right_eye_width_norm
- left_eye_height_norm
- right_eye_height_norm

3.2 嘴部开合特征

驾驶员疲劳时可能出现打哈欠等现象，因此嘴部开合程度也是重要特征。项目计算了 MAR、嘴部宽度、嘴部高度、嘴部开合面积代理值、嘴部与人脸宽度比例，以及 MAR 与 EAR 的组合关系。

相关特征包括：

- mar
- mouth_width_norm
- mouth_height_norm
- mouth_open_area_proxy
- mouth_to_face_width
- mar_to_ear_mean

- `mar_minus_ear_mean`

3.3 人脸几何与头部姿态代理特征

疲劳状态下，驾驶员可能出现低头、偏头或姿态变化。项目没有直接进行三维头姿估计，而是通过二维关键点之间的相对位置关系构造头部姿态代理特征，例如鼻尖位置、鼻尖到下巴距离、额头到下巴距离、左右脸宽比例、眼线角度和嘴线角度等。

相关特征包括：

- `face_width`
- `face_height`
- `face_aspect_ratio`
- `nose_x_norm`
- `nose_y_norm`
- `nose_to_chin_norm`
- `forehead_to_chin_norm`
- `left_right_face_width_ratio`
- `eye_line_angle`
- `mouth_line_angle`

3.4 眉眼距离特征

眉毛和眼睛之间的距离可以反映一定的面部状态变化。项目计算左右眉眼距离、平均眉眼距离以及左右差异，用于辅助判断疲劳状态。

相关特征包括：

- `left_brow_eye_distance_norm`
- `right_brow_eye_distance_norm`
- `brow_eye_distance_mean`
- `brow_eye_distance_diff_abs`

3.5 图像质量特征

实际图像中可能存在亮度不足、对比度较低、模糊等情况，这些因素会影响关键点检测和分类结果。v1 将亮度、对比度和模糊度也作为特征输入模型，使分类器能够一定程度上感知图像质量。

相关特征包括：

- `brightness`
- `contrast`
- `blur_score`

4. 训练设置与超参数

本报告使用 v1 版本的特征和模型配置进行训练。由于当前可用 Python/MediaPipe 环境中无法稳定运行 legacy `mp.solutions.face_mesh.FaceMesh` 接口，本次报告中的分类器训练没有重新运行 MediaPipe 特征提取，而是使用项目已经生成并缓存的 MediaPipe 特征矩阵进行重新训练。也就是说，本次报告确实重新训练了最终的传统机器学习分类器，但特征提取阶段使用的是已有缓存特征。

训练使用的模型管线如下：

```
SimpleImputer(strategy="median") + HistGradientBoostingClassifier
```

主要超参数如下：

参数	取值	说明
特征数量	35	v1 手工特征数量
特征 schema	v1_feature_schema_001	用于保证训练、评估、预测时特征顺序一致
缺失值处理	SimpleImputer(strategy="median")	使用中位数填充缺失特征
分类器	HistGradientBoostingClassifier	直方图梯度提升树分类器
max_iter	250	最大 boosting 迭代次数
learning_rate	0.05	学习率
max_leaf_nodes	15	每棵树最大叶子节点数
l2_regularization	0.01	L2 正则化强度
early_stopping	true	启用早停机制
validation_fraction	0.15	分类器内部早停验证比例
random_state	42	随机种子
类别权重	balanced sample weights	训练时使用 compute_sample_weight(class_weight="balanced") 平衡类别权重


本次训练得到的分类器实际迭代次数为 250，早停机制处于启用状态。

5. 数据集与样本使用情况

在使用 MediaPipe 特征时，部分图片可能因为未检测到人脸而无法提取有效特征。这些图片不会参与最终分类器训练或评估。各数据划分中的样本使用情况如下表所示。

数据划分	原始样本数	有效样本数	未检测到人脸样本数
训练集	46,564	46,076	488
验证集	9,977	9,886	91
测试集	9,980	9,888	92

数据集有效样本分布如下图所示。




6. 训练与验证结果

本次重新训练后，在训练集、验证集和测试集上的整体指标如下。

数据划分	Accuracy	Balanced Accuracy	Macro F1	Weighted F1	ROC AUC
训练集	0.9368	0.9357	0.9361	0.9367	0.9842
验证集	0.9280	0.9267	0.9272	0.9279	0.9792
测试集	0.9239	0.9226	0.9232	0.9239	0.9794

从结果看，训练集准确率为 93.68%，验证集准确率为 92.80%，测试集准确率为 92.39%。训练集与验证集、测试集之间存在一定差距，但差距不大，说明模型没有出现非常严重的过拟合。ROC AUC 在训练集、验证集和测试集上均接近 0.98，说明模型对两类样本具有较强的区分能力。

训练、验证、测试指标对比如下图所示。



6.1 训练集结果

训练集有效样本数为 46,076，混淆矩阵如下：

真实类别 / 预测类别	notdrowsy	drowsy
notdrowsy	19,275	1,588
drowsy	1,325	23,888

训练集分类报告：

类别	Precision	Recall	F1-score	Support
notdrowsy	0.9357	0.9239	0.9297	20,863
drowsy	0.9377	0.9474	0.9425	25,213

6.2 验证集结果

验证集有效样本数为 9,886，混淆矩阵如下：

真实类别 / 预测类别	notdrowsy	drowsy
notdrowsy	4,092	390
drowsy	322	5,082

验证集分类报告：

类别	Precision	Recall	F1-score	Support
notdrowsy	0.9271	0.9130	0.9200	4,482
drowsy	0.9287	0.9404	0.9345	5,404

验证集上，drowsy 类召回率为 0.9404，高于 notdrowsy 类召回率 0.9130，说明模型对疲劳类样本具有较强识别能力，但也会将一部分清醒样本误判为疲劳。

7. 测试集结果与分析

测试集有效样本数为 9,888，整体准确率为 0.9239，ROC AUC 为 0.9794。测试集混淆矩阵如下。


真实类别 / 预测类别	notdrowsy	drowsy
notdrowsy	4,073	411
drowsy	341	5,063

其中：

- 真实为 notdrowsy 且预测正确的样本为 4,073 张；
- 真实为 notdrowsy 但误判为 drowsy 的样本为 411 张；
- 真实为 drowsy 但误判为 notdrowsy 的样本为 341 张；
- 真实为 drowsy 且预测正确的样本为 5,063 张。

测试集混淆矩阵图如下。


Test Confusion Matrix



测试集分类报告如下。


类别	Precision	Recall	F1-score	Support
notdrowsy	0.9227	0.9083	0.9155	4,484
drowsy	0.9249	0.9369	0.9309	5,404

测试集各类别 precision、recall 和 F1-score 对比如下图所示。



从测试集结果可以看出，模型对 `drowsy` 类的召回率为 0.9369，说明大部分疲劳样本可以被成功识别；对 `notdrowsy` 类的召回率为 0.9083，说明仍有部分清醒样本被误判为疲劳。对于驾驶员疲劳检测任务而言，将疲劳样本漏判为清醒通常比将清醒样本误判为疲劳更危险，因此当前模型在疲劳类召回率较高这一点上具有一定优势。

测试集 ROC 曲线如下图所示。



ROC AUC 达到 0.9794，说明模型输出的疲劳概率具有较好的排序能力。即使在不同阈值下调整误报率和漏报率，模型整体仍能保持较强的类别区分效果。

8. 与 v0 基线方法对比

为了说明改进版本的效果，将 v1 与 v0 中的两种基线方法进行比较。当前测试集共有 9,980 张图片，其中 9,888 张检测到人脸并参与有效评估。测试集准确率如下。

版本	方法	特征数量/类型	测试集准确率
v0	规则阈值法	EAR/MAR 阈值	59.74%
v0	SVM	4 个 EAR/MAR 特征	68.72%
v1	HistGradientBoosting	35 个手工特征	92.39%

相比 v0 规则阈值法，v1 的准确率提升约 32.65 个百分点；相比 v0 SVM，v1 的准确率提升约 23.19 个百分点。性能提升主要来自两个方面：

1. **特征更丰富**：v0 主要依赖 EAR/MAR，能够描述眼睛和嘴部开合，但无法充分利用人脸姿态、眉眼关系和图像质量等信息。v1 增加到 35 维特征，使模型可以综合多种线索进行判断。
2. **模型表达能力更强**：规则阈值方法只能表达简单的线性或阈值逻辑；SVM 虽然比规则法更灵活，但输入特征较少。HistGradientBoosting 能够学习多特征之间的非线性组合关系，因此更适合当前任务。

9. 训练产物与图表说明

本次报告生成的主要文件包括：

- report_metrics.json：本次重新训练和评估得到的指标结果。
- hgb_fatigue_report.joblib：本次报告重新训练得到的分类器模型文件。
- report_figures.json：图表路径索引。
- figures/dataset_distribution.png：数据集分布图。
- figures/metric_comparison.png：训练集、验证集、测试集指标对比图。
- figures/test_confusion_matrix.png：测试集混淆矩阵图。
- figures/test_class_metrics.png：测试集分类指标图。
- figures/test_roc_curve.png：测试集 ROC 曲线图。

这些图表均由 matplotlib 生成，并已嵌入到本报告中。

10. 总结与不足

本项目使用 MediaPipe Face Mesh 提取人脸关键点，并基于关键点构造眼睛、嘴部、人脸几何、眉眼距离和图像质量等 35 维手工特征。最终使用 SimpleImputer(strategy="median") + HistGradientBoostingClassifier 作为疲劳状态二分类模型。在本次重新训练和评估中，模型在验证集上达到 92.80% 的准确率，在测试集上达到 92.39% 的准确率，测试集 ROC AUC 达到 0.9794，明显优于 v0 中的规则阈值法和 SVM 基线方法。

该方法的优点是训练成本低、特征含义清晰、模型效果较好，适合课程实践和传统机器学习 baseline 对比。但项目仍存在一些不足：

1. **依赖人脸关键点检测质量**：如果图像中人脸遮挡严重、光照较差、头部角度过大，MediaPipe 可能无法检测到人脸，导致样本被跳过或预测为 unknown。
2. **可能存在数据划分乐观性**：如果相邻帧、同一驾驶员或同一视频片段同时出现在训练集、验证集和测试集中，测试准确率可能偏高，不能完全代表跨驾驶员、跨场景泛化能力。
3. **缺少时间序列信息**：疲劳状态通常与连续闭眼时间、打哈欠持续时间等时序特征有关，而当前模型基于单张图像进行判断，没有使用视频连续帧信息。
4. **不是完整车载安全系统**：实际车载疲劳检测还需要考虑实时性、摄像头稳定性、误报处理、报警策略、夜间红外图像和不同驾驶员个体差异等问题。

后续可以考虑在保持可解释性的基础上加入视频序列统计特征，例如 PERCLOS、连续闭眼帧数、连续打哈欠检测、短时间窗口内的预测平滑等，从而进一步提升疲劳检测系统的稳定性和实用性。